

PHẦN 1: TIỀN XỬ LÝ DỮ LIỆU & CHUẨN HÓA MIN-MAX (PREPROCESSING & NORMALIZATION)

Nội dung: Đọc dữ liệu thô, làm sạch, mã hóa phân loại (One-Hot), chuẩn hóa Min-Max [0, 1] và xuất CSDL SQLite `data/diabetes_pipeline.db`.

I. Data understanding

1. Đọc dữ liệu

```
In [1]: import pandas as pd
import joblib
import os
import sqlite3

# Tự động tìm vị trí tệp dữ liệu linh hoạt khi chạy trong thư mục code/ hoặc ở thư
data_candidates = ['../data/diabetes_dataset.csv', 'data/diabetes_dataset.csv', '..
url = next((p for p in data_candidates if os.path.exists(p)), '../data/diabetes_dat
data = pd.read_csv(url)
print(f'Đọc dữ liệu thành công từ đường dẫn: {url}')

# Tự động tạo thư mục data/ chứa CSDL SQLite
db_dir = '../data' if os.path.exists('../data') or os.path.exists('..') else 'data'
os.makedirs(db_dir, exist_ok=True)
db_path = os.path.join(db_dir, 'diabetes_pipeline.db')
conn_sqlite = sqlite3.connect(db_path)
data.to_sql('raw_dataset', conn_sqlite, if_exists='replace', index=False)
print(f'Đã lưu bảng dữ liệu thô [raw_dataset] vào SQLite: {db_path}')
```

Đọc dữ liệu thành công từ đường dẫn: ../data/diabetes_dataset.csv

Đã lưu bảng dữ liệu thô [raw_dataset] vào SQLite: ../data\diabetes_pipeline.db

2. Xem 5 dòng đầu

```
In [2]: data.head()
```

```
Out[2]:
```

	age	gender	ethnicity	education_level	income_level	employment_status	smoking_status
0	58	Male	Asian	Highschool	Lower-Middle	Employed	Never
1	48	Female	White	Highschool	Middle	Employed	Former
2	60	Male	Hispanic	Highschool	Middle	Unemployed	Never
3	74	Female	Black	Highschool	Low	Retired	Never
4	46	Male	White	Graduate	Middle	Retired	Never

5 rows × 8 columns

3. Xem kích thước

```
In [3]: print(f"Kích thước dữ liệu: {data.shape[0]} dòng, {data.shape[1]} cột")
```

Kích thước dữ liệu: 100000 dòng, 31 cột

4. Danh sách các cột

```
In [4]: list(data.columns)
```

```
Out[4]: ['age',
        'gender',
        'ethnicity',
        'education_level',
        'income_level',
        'employment_status',
        'smoking_status',
        'alcohol_consumption_per_week',
        'physical_activity_minutes_per_week',
        'diet_score',
        'sleep_hours_per_day',
        'screen_time_hours_per_day',
        'family_history_diabetes',
        'hypertension_history',
        'cardiovascular_history',
        'bmi',
        'waist_to_hip_ratio',
        'systolic_bp',
        'diastolic_bp',
        'heart_rate',
        'cholesterol_total',
        'hdl_cholesterol',
        'ldl_cholesterol',
        'triglycerides',
        'glucose_fasting',
        'glucose_postprandial',
        'insulin_level',
        'hba1c',
        'diabetes_risk_score',
        'diabetes_stage',
        'diagnosed_diabetes']
```

5. Kiểu dữ liệu

```
In [5]: data.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 31 columns):
 #   Column                                     Non-Null Count  Dtype
---  -
 0   age                                       100000 non-null  int64
 1   gender                                   100000 non-null  object
 2   ethnicity                               100000 non-null  object
 3   education_level                         100000 non-null  object
 4   income_level                           100000 non-null  object
 5   employment_status                      100000 non-null  object
 6   smoking_status                         100000 non-null  object
 7   alcohol_consumption_per_week           100000 non-null  int64
 8   physical_activity_minutes_per_week     100000 non-null  int64
 9   diet_score                             100000 non-null  float64
10  sleep_hours_per_day                    100000 non-null  float64
11  screen_time_hours_per_day              100000 non-null  float64
12  family_history_diabetes                 100000 non-null  int64
13  hypertension_history                   100000 non-null  int64
14  cardiovascular_history                 100000 non-null  int64
15  bmi                                    100000 non-null  float64
16  waist_to_hip_ratio                     100000 non-null  float64
17  systolic_bp                           100000 non-null  int64
18  diastolic_bp                           100000 non-null  int64
19  heart_rate                             100000 non-null  int64
20  cholesterol_total                      100000 non-null  int64
21  hdl_cholesterol                        100000 non-null  int64
22  ldl_cholesterol                        100000 non-null  int64
23  triglycerides                          100000 non-null  int64
24  glucose_fasting                        100000 non-null  int64
25  glucose_postprandial                   100000 non-null  int64
26  insulin_level                          100000 non-null  float64
27  hba1c                                  100000 non-null  float64
28  diabetes_risk_score                    100000 non-null  float64
29  diabetes_stage                         100000 non-null  object
30  diagnosed_diabetes                     100000 non-null  int64
dtypes: float64(8), int64(16), object(7)
memory usage: 23.7+ MB

```

6. Thống kê dữ liệu số

In [6]: `data.describe()`

Out[6]:

	age	alcohol_consumption_per_week	physical_activity_minutes_per_week	
count	100000.00000	100000.000000	100000.000000	100000.000000
mean	50.12041	2.003670	118.911640	
std	15.60460	1.417779	84.409662	
min	18.00000	0.000000	0.000000	
25%	39.00000	1.000000	57.000000	
50%	50.00000	2.000000	100.000000	
75%	61.00000	3.000000	160.000000	
max	90.00000	10.000000	833.000000	

8 rows × 4 columns

7. Thống kê dữ liệu phân loại

In [7]: `data.describe(include='object')`

Out[7]:

	gender	ethnicity	education_level	income_level	employment_status	smoking_status
count	100000	100000	100000	100000	100000	100000
unique	3	5	4	5	4	4
top	Female	White	Highschool	Middle	Employed	Never
freq	50216	44997	44891	35152	60175	59816

II. Data cleaning

1. Kiểm tra giá trị thiếu (Missing Values)

In [8]:

```
missing = pd.DataFrame({
    'Missing Values': data.isnull().sum(),
    'Percentage (%)': round(data.isnull().mean() * 100, 2)
})
if missing['Missing Values'].sum() == 0:
    print("Tuyệt vời! Không có giá trị thiếu (NaN) nào trong tập dữ liệu.")
else:
    display(missing[missing['Missing Values'] > 0])
```

Tuyệt vời! Không có giá trị thiếu (NaN) nào trong tập dữ liệu.

2. Kiểm tra dữ liệu trùng (Duplicate Records)

In [9]: `print(f"Số dòng trùng lặp: {data.duplicated().sum()}")`

Số dòng trùng lặp: 0

3. Loại bỏ rò rỉ thông tin (Data Leakage) & Biến phái sinh (Giai đoạn 0)

Ta loại bỏ ngay 4 cột ra khỏi dữ liệu thô:

- `diagnosed_diabetes` : Kết quả chẩn đoán trước đó (Leakage trực tiếp).
- `diabetes_stage` : Giai đoạn tiểu đường (Hậu quả của đường huyết - Leakage).
- `glucose_postprandial` : Đường huyết sau ăn (Tương quan trực tiếp - Leakage).
- `diabetes_risk_score` : Điểm nguy cơ tiểu đường (Tổ hợp tuyến tính từ tuổi, BMI, tiền sử gia đình... gây đa cộng tuyến nghiêm trọng).

```
In [10]: # Loại bỏ 4 cột Leakage y khoa và biến phái sinh ở bước làm sạch ban đầu
cols_to_drop = ['diagnosed_diabetes', 'diabetes_stage', 'glucose_postprandial', 'di
data = data.drop(columns=cols_to_drop)
print(f"Kích thước sau khi loại bỏ Leakage: {data.shape}")
```

Kích thước sau khi loại bỏ Leakage: (100000, 27)

4. Chia dữ liệu thành kiểu liên tục, nhị phân, categorical

```
In [11]: numeric_cols = data.select_dtypes(include=['int64', 'float64']).columns
binary_cols = []
continuous_cols = []
for col in numeric_cols:
    unique_values = sorted(data[col].dropna().unique())
    if unique_values == [0, 1]:
        binary_cols.append(col)
    else:
        continuous_cols.append(col)

categorical_cols = data.select_dtypes(include='object').columns
print("Biến liên tục:", continuous_cols)
print("Biến nhị phân:", binary_cols)
print("Biến chữ:", list(categorical_cols))
```

Biến liên tục: ['age', 'alcohol_consumption_per_week', 'physical_activity_minutes_per_week', 'diet_score', 'sleep_hours_per_day', 'screen_time_hours_per_day', 'bmi', 'waist_to_hip_ratio', 'systolic_bp', 'diastolic_bp', 'heart_rate', 'cholesterol_total', 'hdl_cholesterol', 'ldl_cholesterol', 'triglycerides', 'glucose_fasting', 'insulin_level', 'hba1c']

Biến nhị phân: ['family_history_diabetes', 'hypertension_history', 'cardiovascular_history']




Biến chữ: ['gender', 'ethnicity', 'education_level', 'income_level', 'employment_status', 'smoking_status']

5. Kiểm tra outlier trên tập liên tục bằng Boxplot


Nhận xét từ biểu đồ ngoại lai (Boxplot):

- Nhìn vào biểu đồ hộp, ta thấy các biến số sinh học liên tục như BMI (xuất hiện nhiều giá trị cực đoan > 40), triglycerides (> 300) và huyết áp đều xuất hiện nhiều chấm đen ngoại lai kéo dài ở cả hai phía râu hộp.
- Việc có nhiều giá trị ngoại lai cực đoan này nếu để nguyên sẽ gây nhiễu rất lớn cho đường thẳng hồi quy OLS, kéo lệch đường hồi quy và làm tăng sai số dự báo tổng thể.


```
In [12]: import matplotlib.pyplot as plt
import seaborn as sns
for col in continuous_cols:
    if col != 'glucose_fasting':
        plt.figure(figsize=(6,1.5))
        sns.boxplot(data=data, x=col, color='salmon')
        plt.title(f"Boxplot of {col}")
        plt.show()
```




Boxplot of diet_score




Boxplot of sleep_hours_per_day




Boxplot of screen_time_hours_per_day




Boxplot of bmi




Boxplot of waist_to_hip_ratio




Boxplot of systolic_bp




Boxplot of diastolic_bp




Boxplot of heart_rate




Boxplot of cholesterol_total




Boxplot of hdl_cholesterol




Boxplot of ldl_cholesterol



Boxplot of triglycerides





6. Xử lý outlier bằng co đầu mút Capping 1% - 99% (Giai đoạn 1)

Nhận xét về kết quả xử lý ngoại lai bằng Capping:

- Ta áp dụng phương pháp co đầu mút Capping (Winsorization) ở ngưỡng 1% và 99%. Tất cả các giá trị dị biệt vượt ngoài ranh giới này được co về biên an toàn.
- Phương pháp này giúp triệt tiêu hoàn toàn ảnh hưởng của các điểm dị biệt nhiều cho mô hình hồi quy OLS mà không cần xóa bỏ bất kỳ dòng dữ liệu bệnh nhân nào, đảm bảo bảo toàn 100% cỡ mẫu (100,000 dòng) phục vụ nghiên cứu.

```
In [13]: import numpy as np
clean_data = data.copy()
target = 'glucose_fasting'
capping_cols = [col for col in continuous_cols if col != target]

for col in capping_cols:
    lower_limit = data[col].quantile(0.01)
    upper_limit = data[col].quantile(0.99)
    clean_data[col] = np.clip(data[col], lower_limit, upper_limit)

data = clean_data
print("Cập nhật dữ liệu sạch đã capping thành công!")
```


Cập nhật dữ liệu sạch đã capping thành công!



7. Vẽ biểu đồ phân phối sau khi xử lý Outlier

Nhận xét biểu đồ phân phối sau khi Capping (Histogram):


- Sau khi áp dụng Capping, biểu đồ phân phối của các biến liên tục đã được làm sạch phần đuôi ngoại lai kéo dài.
- Phân phối dữ liệu trông gọn gàng, bớt lệch hơn, giúp đáp ứng tốt hơn các giả định phân phối của mô hình hồi quy OLS và làm giảm sai số RMSE khi huấn luyện.

```
In [14]: for col in continuous_cols:
plt.figure(figsize=(7,4))
plt.hist(data[col], bins=30, color='skyblue', edgecolor='black', alpha=0.7)
plt.title(f'Distribution of {col} (After Capping)')
plt.xlabel(col)
plt.ylabel('Frequency')
plt.grid(alpha=0.3)
plt.show()
```







Distribution of diet_score (After Capping)




Distribution of sleep_hours_per_day (After Capping)




Distribution of screen_time_hours_per_day (After Capping)




Distribution of bmi (After Capping)





Distribution of waist_to_hip_ratio (After Capping)




Distribution of systolic_bp (After Capping)







Distribution of cholesterol_total (After Capping)




Distribution of hdl_cholesterol (After Capping)






Distribution of ldl_cholesterol (After Capping)



Distribution of triglycerides (After Capping)







III. Exploratory Data Analysis

1. Phân Tích Dữ Liệu Bằng Truy Vấn SQL Trực Tiếp Trên CSDL SQLite (SQL Exploratory Data Analysis)

Minh chứng kỹ năng Data Analytics thông qua truy vấn SQL (`pandas.read_sql` & `sqlite3`)

```
In [15]: # SQL 1: Thống kê phân bố 3 nhóm Đường huyết Y khoa (Bình thường / Tiền tiểu đường
sql_query1 = """
SELECT
    CASE
        WHEN glucose_fasting < 100 THEN 'Normal (<100 mg/dL)'
        WHEN glucose_fasting BETWEEN 100 AND 125 THEN 'Prediabetes (100-125 mg/dL)'
        ELSE 'Diabetes (>=126 mg/dL)'
    END AS glucose_category,
    COUNT(*) AS patient_count,
    ROUND(COUNT(*) * 100.0 / (SELECT COUNT(*) FROM raw_dataset), 2) AS percentage
FROM raw_dataset
GROUP BY glucose_category
ORDER BY patient_count DESC;
"""

df_sql1 = pd.read_sql(sql_query1, conn_sqlite)
print('=== THỐNG KÊ SQL: PHÂN BỐ NHÓM ĐƯỜNG HUYẾT Y KHOA ===')
print(df_sql1)
```

```

=== THỐNG KÊ SQL: PHÂN BỐ NHÓM ĐƯỜNG HUYẾT Y KHOA ===
      glucose_category  patient_count  percentage
0  Prediabetes (100-125 mg/dL)      65757      65.76
1      Normal (<100 mg/dL)      19715      19.71
2      Diabetes (>=126 mg/dL)      14528      14.53

```

```

In [16]: # SQL 2: Phân tích Đường huyết & HbA1c trung bình theo Tiền sử gia đình & Bệnh Lý n
sql_query2 = """
SELECT
    family_history_diabetes,
    hypertension_history,
    cardiovascular_history,
    COUNT(*) AS total_patients,
    ROUND(AVG(glucose_fasting), 2) AS avg_glucose_mg_dL,
    ROUND(AVG(bmi), 2) AS avg_bmi,
    ROUND(AVG(hba1c), 2) AS avg_hba1c_percent
FROM raw_dataset
GROUP BY family_history_diabetes, hypertension_history, cardiovascular_history
ORDER BY avg_glucose_mg_dL DESC;
"""

df_sql2 = pd.read_sql(sql_query2, conn_sqlite)
print('=== THỐNG KÊ SQL: ĐƯỜNG HUYẾT THEO TIỀN SỬ BỆNH LÝ ===')
print(df_sql2)

```

```

=== THỐNG KÊ SQL: ĐƯỜNG HUYẾT THEO TIỀN SỬ BỆNH LÝ ===
    family_history_diabetes  hypertension_history  cardiovascular_history  \
0                          1                      1                      1
1                          1                      0                      1
2                          1                      1                      0
3                          1                      0                      0
4                          0                      1                      1
5                          0                      0                      1
6                          0                      1                      0
7                          0                      0                      0

    total_patients  avg_glucose_mg_dL  avg_bmi  avg_hba1c_percent
0                505             121.86   25.84              7.01
1               1246             121.43   25.73              6.97
2              5057             120.75   25.72              6.92
3             15133             119.51   25.56              6.87
4              1741             110.76   25.71              6.53
5              4428             110.13   25.73              6.50
6             17777             109.68   25.69              6.46
7             54113             108.10   25.57              6.39

```

```

In [17]: # SQL 3: Tương quan chỉ số BMI, HbA1c và Đường huyết đối theo nhóm độ tuổi
sql_query3 = """
SELECT
    CASE
        WHEN age < 30 THEN 'Under 30'
        WHEN age BETWEEN 30 AND 50 THEN '30 - 50 years'
        ELSE 'Over 50'
    END AS age_group,
    COUNT(*) AS total_patients,
    ROUND(AVG(bmi), 2) AS avg_bmi,
    ROUND(AVG(hba1c), 2) AS avg_hba1c,

```

```

        ROUND(AVG(glucose_fasting), 2) AS avg_glucose
FROM raw_dataset
GROUP BY age_group
ORDER BY avg_glucose DESC;
"""
df_sql3 = pd.read_sql(sql_query3, conn_sqlite)
print('=== THỐNG KÊ SQL: CHỈ SỐ THEO NHÓM ĐỘ TUỔI ===')
print(df_sql3)

```

=== THỐNG KÊ SQL: CHỈ SỐ THEO NHÓM ĐỘ TUỔI ===

	age_group	total_patients	avg_bmi	avg_hba1c	avg_glucose
0	Over 50	48820	25.88	6.63	113.72
1	30 - 50 years	41178	25.43	6.45	109.35
2	Under 30	10002	25.03	6.30	105.69

2. Bar Chart (Biểu đồ cột tần suất)


Nhận xét phân bố các biến phân loại:

- Biểu đồ cột cho thấy sự phân bố số lượng mẫu trên các nhóm của các biến chữ như giới tính, chủng tộc, học vấn, việc làm, tình trạng hút thuốc.
- Số lượng mẫu phân bố khá đều giữa các nhóm chính, đảm bảo mô hình không bị lệch dữ liệu (data imbalance) nghiêm trọng ở các đặc trưng nhân khẩu học xã hội này.


```

In [18]: for col in categorical_cols:
plt.figure(figsize=(6,3))
data[col].value_counts().plot(kind='bar', color='teal', alpha=0.8)
plt.title(f"Tần suất nhóm trong {col}")
plt.ylabel("Count")
plt.show()


```






Tần suất nhóm trong ethnicity



Tần suất nhóm trong education_level







3. Encoding (Giai đoạn 3)

```
In [19]: # Lưu bản sao dữ liệu gốc trước khi số hóa để dùng cho phân tích ANOVA
data_before_encoding = data.copy()

categorical_cols = data.select_dtypes(include='object').columns
data = pd.get_dummies(data, columns=categorical_cols, drop_first=True, dtype=int)

# Đưa biến mục tiêu glucose_fasting xuống cuối bảng dữ liệu để Heatmap hiển thị ở d
target = 'glucose_fasting'
cols = [c for c in data.columns if c != target] + [target]
data = data[cols]
print(f"Kích thước sau khi One-Hot Encode và đưa target về cuối: {data.shape}")
```

Kích thước sau khi One-Hot Encode và đưa target về cuối: (100000, 39)


4. Correlation Heatmap (Mở rộng - 38 cột)

Phân tích ma trận tương quan mở rộng sau khi đã mã hóa dummy (38 cột):

- Biến mục tiêu `glucose_fasting` có mối tương quan dương mạnh nhất với `hba1c` ($r = 0.70$), theo sau là `insulin_level` ($r = 0.45$). Đây là điều hoàn toàn phù hợp với thực tế lâm sàng vì HbA1c và Insulin phản ánh trực tiếp trạng thái hóa sinh đường huyết.
- Các yếu tố hành vi lối sống như thời gian xem màn hình (`screen_time`), thời gian vận động (`physical_activity`), điểm chế độ ăn (`diet_score`) có tương quan tuyến tính đơn lẻ rất yếu với đường huyết ($r < 0.1$).
- Giữa các biến độc lập với nhau: Ngoại trừ duy nhất cặp biến hình thể `bmi` và `waist_to_hip_ratio` có tương quan khá mạnh ($r = 0.76$, điều này hoàn toàn hợp lý về mặt y khoa), không xuất hiện cặp biến độc lập nào khác có tương quan vượt quá 0.6.

Kiểm chứng định lượng bằng chỉ số VIF ở bước sau cho thấy cả hai biến này đều có VIF dưới 3 (nằm trong khoảng an toàn), do đó chúng không gây đa cộng tuyến nghiêm trọng và được giữ lại để tăng độ chính xác của mô hình.

```
In [20]: corr = data.corr(numeric_only=True)
plt.figure(figsize=(20,16))
sns.heatmap(corr, annot=True, cmap="coolwarm", fmt=".2f", linewidths=0.5, annot_kws=
plt.title("Correlation Matrix (Fully Encoded - 38 Columns)")
plt.show()
```



5. Đánh giá đa cộng tuyến VIF sau khi vẽ Heatmap

Phân tích kết quả chạy VIF lần đầu:

- Chỉ số VIF đo lường mức độ đa cộng tuyến giữa các biến độc lập. Nếu VIF > 10, biến đó bị đa cộng tuyến mạnh và cần loại bỏ.
- Kết quả bảng VIF bên dưới chỉ ra đặc trưng `ldl_cholesterol` có VIF = 10.387 (vượt ngưỡng 10), đồng thời `cholesterol_total` và `diastolic_bp` cũng có VIF rất cao do cộng tuyến tuyến tính với các biến liên quan.

```
In [21]: import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor

# Chuẩn bị tập các biến độc lập (Loại bỏ target glucose_fasting)
X_vif_raw = data.drop(columns=['glucose_fasting'])
X_vif_raw = sm.add_constant(X_vif_raw.astype(float))
vif_raw_df = pd.DataFrame()
vif_raw_df["Feature"] = X_vif_raw.columns
vif_raw_df["VIF"] = [variance_inflation_factor(X_vif_raw.values, i) for i in range(X_vif_raw.shape[0])]
print("--- BẢNG CHỈ SỐ VIF TRÊN DỮ LIỆU SỐ HÓA BAN ĐẦU ---")
print(vif_raw_df.sort_values(by='VIF', ascending=False).head(15))
```

--- BẢNG CHỈ SỐ VIF TRÊN DỮ LIỆU SỐ HÓA BAN ĐẦU ---

	Feature	VIF
0	const	901.966867
17	ldl_cholesterol	10.417232
15	cholesterol_total	9.494741
32	income_level_Middle	5.208256
31	income_level_Lower-Middle	4.514347
33	income_level_Upper-Middle	3.986376
30	income_level_Low	3.378554
10	bmi	2.996038
26	ethnicity_White	2.636917
11	waist_to_hip_ratio	2.409099
24	ethnicity_Hispanic	2.153604
23	ethnicity_Black	2.064370
16	hdl_cholesterol	1.913450
38	smoking_status_Never	1.648409
1	age	1.643270

6. Loại bỏ biến đa cộng tuyến và tính toán lại VIF

Nhận xét sau khi loại bỏ ldl_cholesterol:

- Sau khi loại bỏ đặc trưng `ldl_cholesterol` (biến duy nhất có VIF > 10), chỉ số VIF của toàn bộ các đặc trưng còn lại (bao gồm cả `cholesterol_total` và `diastolic_bp`) đều **nhỏ hơn 5.3** (nằm hoàn toàn dưới ngưỡng an toàn là 10).
- Dữ liệu lúc này đã hoàn toàn sạch đa cộng tuyến, sẵn sàng đưa vào bước chia train/test và chuẩn hóa.

```
In [22]: # Loại bỏ biến ldl_cholesterol bị đa cộng tuyến phát hiện qua kiểm định VIF
data = data.drop(columns=['ldl_cholesterol'])

# Tính toán lại VIF để kiểm chứng
X_vif_clean = data.drop(columns=['glucose_fasting'])
X_vif_clean = sm.add_constant(X_vif_clean.astype(float))
vif_clean_df = pd.DataFrame()
vif_clean_df["Feature"] = X_vif_clean.columns
vif_clean_df["VIF"] = [variance_inflation_factor(X_vif_clean.values, i) for i in range(X_vif_clean.shape[0])]
print("--- BẢNG CHỈ SỐ VIF SAU KHI LOẠI BỎ BIẾN ĐA CỘNG TUYẾN ---")
print(vif_clean_df.sort_values(by='VIF', ascending=False).head(10))
```

--- BẢNG CHỈ SỐ VIF SAU KHI LOẠI BỎ BIẾN ĐA CỘNG TUYẾN ---

	Feature	VIF
0	const	897.145368
31	income_level_Middle	5.208213
30	income_level_Lower-Middle	4.514277
32	income_level_Upper-Middle	3.986351
29	income_level_Low	3.378488
10	bmi	2.995913
25	ethnicity_White	2.636910
11	waist_to_hip_ratio	2.408992
23	ethnicity_Hispanic	2.153564
22	ethnicity_Black	2.064368

IV. Data Preprocessing

1. Tách X và y

```
In [23]: target = "glucose_fasting"
X = data.drop(columns=[target])
y = data[target]
```

2. Chia train/test (Thực hiện khi chuẩn bị train theo Cách A)

```
In [24]: from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
print(f"Train size: {X_train.shape}")
print(f"Test size: {X_test.shape}")
```

Train size: (80000, 37)

Test size: (20000, 37)

4. Chuẩn hóa đặc trưng liên tục

```
In [ ]: from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
cols_to_scale = [c for c in continuous_cols if c != target and c in X_train.columns]

X_train[cols_to_scale] = scaler.fit_transform(X_train[cols_to_scale])
X_test[cols_to_scale] = scaler.transform(X_test[cols_to_scale])
print('Hoàn thành chuẩn hóa đặc trưng liên tục về khoảng [0, 1]!')

# Lưu các tập dữ liệu Chuẩn hóa (Normalization) & Splits vào SQLite data/diabetes_p
X_train.to_sql('X_train_normalized', conn_sqlite, if_exists='replace', index=False)
X_test.to_sql('X_test_normalized', conn_sqlite, if_exists='replace', index=False)
pd.DataFrame({'target': y_train}).to_sql('y_train', conn_sqlite, if_exists='replace', index=False)
pd.DataFrame({'target': y_test}).to_sql('y_test', conn_sqlite, if_exists='replace', index=False)
print('Đã lưu các bảng [X_train_normalized], [X_test_normalized], [y_train], [y_test] vào SQLite!')
```

Hoàn thành chuẩn hóa đặc trưng liên tục về khoảng [0, 1]!

Đã lưu các bảng [X_train_normalized], [X_test_normalized], [y_train], [y_test] vào SQLite!