

PHẦN 03

LÀM SẠCH & CHUẨN HÓA DỮ LIỆU

(DATA CLEANING & DATA NORMALIZATION)

Dự án: Dự đoán chỉ số Đường huyết đói (Glucose Fasting)
từ bộ dữ liệu lâm sàng & nhân khẩu học 100.000 bệnh nhân

Tài liệu báo cáo được biên soạn dựa trên toàn bộ quy trình xử lý
trong notebook [Project_ADY301.ipynb](#)

I. Kiểm tra chất lượng dữ liệu thô

1. Giá trị thiếu (Missing Values)

Kiểm tra bằng `data.isnull().sum()` trên toàn bộ 100.000 dòng × 31 cột dữ liệu thô cho kết quả: **không tồn tại bất kỳ giá trị thiếu (NaN) nào** trong toàn bộ tập dữ liệu. Đây là điều kiện lý tưởng, giúp bỏ qua hoàn toàn bước điền khuyết (imputation) thường tốn nhiều công sức và có thể gây nhiễu nếu xử lý không đúng cách.

2. Dữ liệu trùng lặp (Duplicate Records)

Kiểm tra bằng `data.duplicated().sum()` : kết quả **0 dòng trùng lặp**. Bộ dữ liệu đảm bảo mỗi bệnh nhân chỉ xuất hiện một lần duy nhất, không cần loại bỏ bản ghi trùng.

0

GIÁ TRỊ THIẾU (NaN)

0

DÒNG TRÙNG LẶP

4

CỘT BỊ LOẠI VÌ LEAKAGE

3. Loại bỏ rò rỉ thông tin (Data Leakage) & biến phái sinh

✦ Trọng tâm xử lý — Bước quyết định độ tin cậy của mô hình

Bốn cột sau được loại bỏ **ngay từ đầu** khỏi dữ liệu thô vì chúng gây rò rỉ thông tin (data leakage) — nghĩa là chúng chứa thông tin được tính toán/suy ra từ *chính* hoặc *sau khi biết* giá trị đường huyết, khiến mô hình "gian lận" khi huấn luyện và mất khả năng dự đoán thực tế trên dữ liệu mới:

- `diagnosed_diabetes` — Kết quả chẩn đoán tiểu đường trước đó (leakage trực tiếp).
- `diabetes_stage` — Giai đoạn tiểu đường, là **hậu quả** của đường huyết cao, không phải nguyên nhân.
- `glucose_postprandial` — Đường huyết sau ăn, có tương quan trực tiếp và gần như song hành với đường huyết đói — nếu giữ lại, mô hình sẽ "đoán" gần như hoàn hảo một cách không thực tế.
- `diabetes_risk_score` — Điểm nguy cơ tiểu đường, vốn là tổ hợp tuyến tính từ tuổi, BMI, tiền sử gia đình... nên gây đa cộng tuyến nghiêm trọng nếu đưa vào mô hình cùng các biến gốc.

Sau bước này, kích thước dữ liệu giảm từ **31 cột → 27 cột** (giữ nguyên 100.000 dòng).

4. Phân loại các nhóm biến số


Dữ liệu 27 cột được phân chia thành 3 nhóm để phục vụ các bước xử lý khác nhau (capping cho biến liên tục, giữ nguyên cho biến nhị phân, mã hóa cho biến chữ):

Nhóm biến	Số lượng	Danh sách tiêu biểu
Biến liên tục (continuous)	18	age, bmi, waist_to_hip_ratio, systolic_bp, diastolic_bp, heart_rate, cholesterol_total, hdl_cholesterol, ldl_cholesterol, triglycerides, insulin_level, hba1c, glucose_fasting...
Biến nhị phân (binary 0/1)	3	family_history_diabetes, hypertension_history, cardiovascular_history
Biến phân loại dạng chữ (categorical)	6	gender, ethnicity, education_level, income_level, employment_status, smoking_status


II. Xử lý giá trị ngoại lai (Outlier Treatment)

1. Phát hiện outlier bằng Boxplot (trước xử lý)


Toàn bộ 17 biến liên tục (trừ biến mục tiêu `glucose_fasting`) được kiểm tra trực quan bằng biểu đồ hộp (Boxplot) để phát hiện các điểm dữ liệu dị biệt.



Boxplot: age (Tuổi)




Boxplot: alcohol_consumption_per_week (Rượu/tuần)




Boxplot: physical_activity_minutes_per_week (Vận động)




Boxplot: diet_score (Điểm ăn uống)




Boxplot: sleep_hours_per_day (Giờ ngủ)




Boxplot: screen_time_hours_per_day (Giờ màn hình)




Boxplot: bmi (Chỉ số khối cơ thể)




Boxplot: waist_to_hip_ratio (Tỷ lệ eo/hông)



Boxplot: systolic_bp (Huyết áp tâm thu)




Boxplot: diastolic_bp (Huyết áp tâm trương)




Boxplot: heart_rate (Nhịp tim)




Boxplot: cholesterol_total (Cholesterol tổng)




Boxplot: hdl_cholesterol (Cholesterol tốt)




Boxplot: ldl_cholesterol (Cholesterol xấu)



Boxplot: triglycerides (Mỡ máu)



Boxplot: insulin_level (Insulin)



Boxplot: hba1c (HbA1c)

✦ Nhận xét chính từ Boxplot

Các biến số sinh học liên tục như **BMI** (xuất hiện nhiều giá trị cực đoạn > 40), **triglycerides** (> 300) và **huyết áp** đều xuất hiện nhiều chấm đen ngoại lai kéo dài ở cả hai phía râu hộp. Việc có nhiều giá trị ngoại lai cực đoạn này nếu để nguyên sẽ gây nhiễu rất lớn cho đường thẳng hồi quy OLS, kéo lệch đường hồi quy và làm tăng sai số dự báo tổng thể.

2. Xử lý outlier bằng phương pháp co đầu mút Capping (Winsorization 1% - 99%)


Thay vì xóa bỏ các dòng dữ liệu chứa outlier (gây mất mẫu quý giá), nhóm áp dụng kỹ thuật **Capping (Winsorization)** ở ngưỡng phân vị 1% và 99%: mọi giá trị vượt ra ngoài khoảng `[ quantile(0.01), quantile(0.99) ]` sẽ được "co" (clip) về đúng ranh giới đó bằng hàm `numpy.clip()`.

✦ Trọng tâm phương pháp — Vì sao chọn Capping thay vì xóa dòng?


Phương pháp Capping giúp **triệt tiêu hoàn toàn ảnh hưởng của các điểm dị biệt** gây nhiễu cho mô hình hồi quy OLS mà **không cần xóa bỏ bất kỳ dòng dữ liệu bệnh nhân nào**, đảm bảo bảo toàn **100% cỡ mẫu (100.000 dòng)** phục vụ nghiên cứu — điều đặc biệt quan trọng với dữ liệu y khoa vốn

3. Phân phối dữ liệu sau khi Capping (Histogram)


Sau capping, phân phối của toàn bộ 18 biến liên tục (bao gồm cả biến mục tiêu) được trực quan hóa lại bằng Histogram để xác nhận hiệu quả xử lý:




Sau Capping: age




Sau Capping: alcohol_consumption_per_week




Sau Capping: physical_activity_minutes_per_week




Sau Capping: diet_score




Sau Capping: sleep_hours_per_day




Sau Capping: screen_time_hours_per_day




Sau Capping: bmi




Sau Capping: waist_to_hip_ratio




Sau Capping: systolic_bp




Sau Capping: diastolic_bp




Sau Capping: heart_rate




Sau Capping: cholesterol_total




Sau Capping: hdl_cholesterol




Sau Capping: ldl_cholesterol




Sau Capping: triglycerides



Sau Capping: glucose_fasting (TARGET)



Sau Capping: insulin_level



Sau Capping: hba1c

✦ Nhận xét chính sau Capping

Sau khi áp dụng Capping, biểu đồ phân phối của các biến liên tục đã được làm sạch phần đuôi ngoại lai kéo dài. Phân phối dữ liệu trông gọn gàng, bớt lệch hơn, giúp đáp ứng tốt hơn các giả định phân phối của mô hình hồi quy OLS và **làm giảm sai số RMSE** khi huấn luyện ở giai đoạn Training.

III. Tiền xử lý dữ liệu cho Mô hình hóa (Data Preprocessing)

1. Mã hóa biến phân loại (Encoding)

6 biến phân loại dạng chữ được số hóa bằng `pd.get_dummies(..., drop_first=True, dtype=int)`, mở rộng dữ liệu từ 27 cột lên **39 cột**. Một bản sao dữ liệu trước khi mã hóa (`data_before_encoding`) được lưu lại riêng để phục vụ phân tích ANOVA nguyên bản theo nhóm ở tài liệu Phần 04.

2. Loại bỏ biến đa cộng tuyến (dựa trên phân tích VIF ở Phần 02)

Đặc trưng `ldl_cholesterol` (VIF = 10.417, vượt ngưỡng an toàn) được loại bỏ khỏi tập dữ liệu. Sau bước này, dữ liệu còn lại **38 cột**, toàn bộ VIF các đặc trưng còn lại đều nhỏ hơn 5.3, hoàn toàn sạch đa cộng tuyến.

3. Tách biến độc lập (X) và biến mục tiêu (y)

Dữ liệu được tách thành ma trận đặc trưng `X` (37 cột, sau khi loại bỏ target) và vector mục tiêu `y = glucose_fasting`.

4. Chia tập Train / Test

Sử dụng `train_test_split(test_size=0.2, random_state=42)` để chia dữ liệu theo tỷ lệ 80/20, đảm bảo khả năng đánh giá mô hình khách quan trên dữ liệu chưa từng được nhìn thấy:

Tập dữ liệu	Số dòng	Số cột (đặc trưng)
Train (huấn luyện)	80.000	37
Test (kiểm định)	20.000	37

5. Chuẩn hóa đặc trưng liên tục (Normalization)

✦ Trọng tâm chuẩn hóa — Kỹ thuật MinMaxScaler

Toàn bộ đặc trưng liên tục được chuẩn hóa về khoảng **[0, 1]** bằng `MinMaxScaler` của scikit-learn. Điểm mấu chốt về mặt kỹ thuật (tránh rò rỉ thông tin lẫn hai - *data leakage khi chuẩn hóa*): scaler chỉ được `fit()` trên tập **Train**, sau đó dùng để `transform()` cho cả Train và Test — đảm bảo thông tin thống kê (min, max) của tập Test không "rò rỉ ngược" vào quá trình huấn luyện.

Sau khi hoàn tất, các bảng dữ liệu `X_train_normalized`, `X_test_normalized`, `y_train`, `y_test` được lưu trữ vào cơ sở dữ liệu SQLite (`data/diabetes_pipeline.db`) để tái sử dụng xuyên suốt pipeline huấn luyện mô hình.

✓ Tổng kết Pipeline làm sạch & chuẩn hóa

Bước xử lý	Kết quả
Dữ liệu thô ban đầu	100.000 dòng × 31 cột
Sau loại bỏ Data Leakage	100.000 dòng × 27 cột
Sau One-Hot Encoding	100.000 dòng × 39 cột
Sau loại bỏ đa cộng tuyến (VIF)	100.000 dòng × 38 cột
Sau chia Train/Test & Chuẩn hóa	Train: 80.000 — Test: 20.000 (37 đặc trưng đầu vào)